

R tidyverse 마스터 클래스

4강 - 우리만의 데이터 베이스 만들기

슬기로운통계생활

Issac Lee





서울시 이동데이터 데이터베이스 만들기



이동 데이터 다운받기



서울시 이동데이터

- 홈페이지 이동
- 자치구 단위 데이터에서 21년 1월 데이터를 다운받자. 자신의 컴퓨터 용량이 작다면 1월과 8월 데이터만 다운 받자.
- 링크 클릭하면 다음과 같은 2개 파일이 다운 받아진다.
 - 생활이동_자치구_202101.zip
 - ...
 - 생활이동_자치구_202108.zip
- 압축을 풀게 되면, 각 월별 (폴더)에 24개의 파일 (시간별 기록)이 생기게 된다.



폴더 구조 및 자료 구조 보기

1개월 24개 파일
월별 1GB

```
list.dirs("./data/")
```

```
## [1] "./data/"  
## [2] "./data//생활이동_자치구_202101"
```

```
list.files("./data/생활이동_자치구_202101/") %>% head()
```

```
## [1] "생활이동_자치구_202101_00시.csv"  
## [2] "생활이동_자치구_202101_01시.csv"  
## [3] "생활이동_자치구_202101_02시.csv"  
## [4] "생활이동_자치구_202101_03시.csv"  
## [5] "생활이동_자치구_202101_04시.csv"  
## [6] "생활이동_자치구_202101_05시.csv"
```

Data base 만들기



R code

- 강의 페이지에서 R code를 굵어 복사 붙여넣기 해주세요.
- folder_names에는 다음과 같이 csv파일이 들어가 있는 폴더 이름들이 들어가 있다.

```
folder_names <- list.dirs("./data")[2]  
folder_names
```

```
## [1] "./data/생활이동_자치구_202101"
```

- 코드는 list.files() 함수를 사용하여 파일 이름을 불러오고, 그 이름들을 사용하여 csv 파일을 하나씩 불러와 db 파일에 seoul_moving_data 테이블에 이어 붙이도록 되어있다.

전체 데이터 베이스 탐색



RSQLite를 사용한 DB 연결

```
library(DBI)
library(tidyverse)
library(magrittr)
con <- dbConnect(RSQLite::SQLite(),
                  "./data/movingdata_seoul.db")
dbListTables(con)[1:2]
```

```
## [1] "reference_data"      "seoul_moving_data_2021"
```

```
moving_db <- tbl(con, "seoul_moving_data_2021")
reference_db <- tbl(con, "reference_data")
```

월별 이동량



- 총 2억 천 7백만건 데이터

```
moving_db %>% tally()
```

```
moving_db %>%  
  group_by(month) %>%  
  tally()
```

```
## # Source:   lazy query [?? x 2]  
## # Database: sqlite 3.36.0  
## #   [C:\Users\issac\Documents\Teaching\F  
##   month      n  
##   <dbl>      <int>  
## 1         1 24351892  
## 2         2 25610731  
## 3         3 27468233  
## 4         4 27733676  
## 5         5 28753287  
## 6         6 28313847  
## 7         7 27587624  
## 8         8 27464405
```



내가 원하는 데이터 뽑아내기

서울시 출근 인구

```
commute_data <- moving_db %>%  
  filter(trip_type == "HW" &  
         departure_code < 20000 &  
         arrival_code < 20000) %>% # 서울 내 이동  
  mutate(generation =  
         case_when(  
           between(age, 0, 25) ~ "청년층",  
           between(age, 25, 60) ~ "중년층",  
           age >= 65 ~ "장년층",  
           TRUE ~ as.integer(age)  
         )) %>%  
  group_by(month, generation) %>%  
  summarise(population = sum(population, na.rm = TRUE)) %>%  
  collect()
```


데이터 변환하기



dbplyr와 dplyr의 차이

추가적인 데이터 처리

- Factor level의 재조정 같은 경우 dbplyr에서 할 수 없음.
- 기반 데이터를 뽑아낸 후 알맞게 변형

```
commute_data %<>%  
  mutate(population =  
    round(population / 10000, digits = 1)) %>%  
  mutate(generation = factor(generation,  
                             levels = c("청년층", "중년층", "장년층")))
```

그래프 작성하기



Esquisse 패키지

- 기본 틀을 작성 후 수정

```
p <- ggplot(commute_data) +  
  aes(x = month, y = population, fill = population) +  
  geom_bar(stat="identity") +  
  scale_fill_gradient(low = "#231AE4", high = "#F00202") +  
  labs(  
    x = "월 (2021년 기준)",  
    y = "인구이동량 (단위: 만명)",  
    title = "세대별 월별 인구 출근 이동량",  
    fill = "인구이동량"  
  ) +  
  theme_minimal() +  
  theme(legend.position = "right") +  
  facet_wrap(vars(generation))
```

세대별 월별 출근 인구변화



인사이트?



같이 보면 좋은 책 추천

[1] R for Data Science

- 웹 상에 무료 공개된 책입니다.
- 위 교재의 한글 번역본 **R 을 활용한 데이터과학**도 있습니다.
- 도서 제목 클릭하셔서 구매하시면 저의 **사리사욕**을 충당하는데 도움이 됩니다.

